

LLM Wiki 초안 검토 및 자기개선 통합 설계 보고서

[Bilevel Autoresearch](#) · [SlopCodeBench](#) · [Meta-Harness](#) ·
[karpathy/autoresearch](#) · [autoresearch-skill](#) · [jangpm-meta-skills](#) · [Ouroboros 반영안](#)

핵심 결론

현재 초안은 raw/wiki 분리, flat wiki, append-only log 라는 좋은 뼈대를 이미 갖고 있다.

- 가장 큰 결핍은 canonical page 의 실제 부재, deterministic lint/eval 부재, 그리고 mechanism-level self-improvement 정의 부재다.
- 권장 방향은 위키를 버리고 새 프레임워크로 갈아타는 것이 아니라, 위키를 memory layer 로 유지한 채 ops layer 와 3 중 루프를 덧붙이는 것이다.

검토 대상

업로드된 LLM Wiki 초안(AGENTS/index/log), Stage 1 MVP spec, 첨부 논문 3 편, GitHub 저장소 4 개, 관련 project/design pages

작성일: 2026-04-12

1. 검토 범위와 총평

본 검토는 초안 vault 의 운영 규칙(AGENTS.md), index/log, Stage 1 MVP specification, 업로드된 연구 논문 3 편, 그리고 4 개 GitHub 저장소의 자기개선 방향을 함께 대조해 작성했다. 보고서의 목적은 ‘무엇이 좋은가’를 칭찬하는 데서 끝나는 것이 아니라, 현재 초안을 실제로 굴릴 수 있는 self-improving wiki runtime 으로 재구성하는 것이다.

구분	검토 항목	핵심 용도
초안	AGENTS.md / index.md / log.md	현재 운영 원칙과 bootstrap 상태 진단
구현 명세	Stage 1 MVP Specification	planning gate / artifact contract / state machine
논문	Bilevel Autoresearch / SlopCodeBench / Meta-Harness	outer-loop, anti-slop, trace-first optimization
저장소	karpthy/autoresearch / autoresearch-skill / jangpm-meta-skills / Ouroboros	실전형 운영 패턴과 command surface

총평

- 초안의 철학은 옳다. raw 를 불변 계층으로 두고 wiki 를 mutable layer 로 두는 구조는 앞으로도 유지하는 편이 맞다.
- 다만 현재 상태는 ‘좋은 운영 선언문’에 가깝고, 아직 ‘자기개선 가능한 런타임’은 아니다.
- 가장 좋은 다음 단계는 거대한 multi-agent 시스템을 붙이는 것이 아니라, canonical page + ops layer + planning gate + keep/discard meta-loop 를 순서대로 추가하는 것이다.

2. 현재 초안 평가

2.1 이미 잘 잡혀 있는 부분

강점	의미	유지 여부
raw / wiki 분리	source fidelity 를 지키고 correction 이 가능하다.	그대로 유지
flat wiki + prefix naming	bootstrap 단계의 구조 마찰을 낮춘다.	그대로 유지
append-only log	chronology 와 rationale 을 잃지 않는다.	그대로 유지
source fidelity 강조	추후 meta-loop 가 과적합으로 흐르는 것을 막는다.	그대로 유지

2.2 보완이 필요한 부분

관찰	위험	패키지의 처리
등록 source path mismatch	source discovery 가 깨지고 index 신뢰성이 떨어진다.	실제 파일명으로 정정
canonical page 부재	재사용 가능한 knowledge layer 가 형성되지 않는다.	source/concept/synthesis 23 개 페이지 추가
repo snapshot 부재	향후 live web 의존성이 커진다.	web snapshot raw 추가
deterministic lint/eval 부재	품질 판정이 감과 기억에 의존한다.	`ops/` layer 와 script 추가

reflect/query artifact 습관 부재	세션 경계에서 의사결정이 사라진다.	`query--` / `lint--` page 추가
mechanism-level improve 정의 부재	self-improvement 가 content editing 으로만 축소된다.	3 중 루프 아키텍처 제안

3. 외부 소스에서 가져올 핵심 방향

출처	가져올 것	LLM Wiki 적용 방식
[P1] Bilevel Autoresearch	content 개선과 mechanism 개선 분리	outer loop 가 policy/template/script 를 바꾸게 설계
[P2] SlopCodeBench	prompt-only hygiene 의 한계, 구조적 anti-slop 필요	duplicate/orphan/weak-trace 를 governance 대상화
[P3] Meta-Harness	full-history filesystem + trace-first diagnosis	log/snapshot/manifest/lint/eval raw access 보존
[R1] karpathy/autoresearch	baseline, one-unit mutation, keep/discard	page/policy mutation 을 한 번에 하나씩 수행
[R2] autoresearch-skill	binary eval, results log, changelog	`wiki_eval.py` 와 append-only change rationale 채택
[R3] jangpm-meta-skills	blueprint/deep-dive/autoresearch/reflect workflow	ingest/query/reflect 를 작업 흐름으로 고정
[R4] Ouroboros	spec-first, seed freeze, gate, persistent loop	planning bundle 과 major synthesis 에만 gate 도입
[S1] Stage 1 MVP spec	artifact contract, validation, signoff	wiki 를 planning harness 의 evidence layer 로 연결

4. 권장 목표 아키텍처

권장 구조는 4 계층 저장소와 3 중 루프를 결합한 형태다.

```

RAW (immutable PDFs + snapshots)
  -> WIKI (source / concept / synthesis / query / lint)
  -> OPS (policy / eval / schema / scripts)
  -> RULES (AGENTS.md)

Inner loop      : ingest / query / page update / lint / eval / keep-discard
Planning loop   : interview / seed freeze / plan / validate / signoff
Outer meta-loop : inspect traces / mutate one mechanism / re-evaluate / promote-revert

```

4.1 루프별 책임 분리

루프	주 입력	주 출력	선택 규칙
Content maintenance	raw source, user query, prior canonical pages	updated wiki pages, index/log 갱신	binary eval + lint
Planning gate	ambiguous request, existing bundle/wiki context	seed, plan, task graph, validation, signoff	PASS/WARN/FAIL
Mechanism improvement	page diff, lint/eval report, snapshots, log	template/policy/script/command 변경	keep/discard/revert

4.2 왜 이 구조가 적절한가

- 위키 내용만 바꾸면 운영 슬롭이 누적된다.
- 정책만 바꾸면 실제 지식 층이 비어 있을 수 있다.
- planning gate 가 없으면 ambiguity 가 큰 synthesis 가 너무 빨리 canonical page 가 된다.
- raw immutable layer 가 있어야 future correction 과 source fidelity 가 가능하다.

5. 실행 로드맵

단계	기간	목표	구체 작업
Phase 0	즉시	baseline 정리	package 채택, lint/eval 실행, canonical 용어 합의
Phase 1	1-3 일	실제 ingest 루프 검증	source 1 건 추가 ingest, query artifact 1 건 저장
Phase 2	1 주	planning gate 파일럿	seed freeze + validation + signoff 를 1 건 운영
Phase 3	2-3 주	meta-loop 시작	template/policy 대상으로 keep/discard 실험 1-3 회
Phase 4	후속	trace-first outer loop 확장	script patch, dashboard, persistent run ledger 도입

시작 순서 제안

- 바로 full Ouroboros 화하지 않는다.
- meta-improvement 는 page 내용보다 template/policy 부터 시작한다.
- planning gate 는 모든 page 가 아니라 planning bundle 과 controversial synthesis 에만 먼저 도입한다.
- binary eval 은 5~7 개로 시작하고, 점수가 같으면 revert 하는 보수적 기준을 쓴다.

6. ZIP 패키지 구성

본 패키지는 총 27 개의 wiki markdown, 4 개의 PDF raw source, 7 개의 web snapshot, 14 개의 ops files 를 포함한다.

영역	핵심 내용	수량/예시
`wiki/`	source / concept / synthesis / lint / query pages	27 files (8 source, 10 concept, 5 synthesis)
`raw/`	업로드 PDF + immutable web snapshots	4 PDFs, 7 snapshots
`ops/`	policy, eval, schema, lint/eval/manifest scripts	14 files
root	AGENTS.md, README.md, .obsidian	vault bootstrap + usage guide

패키지에서 바로 써볼 파일

- `wiki/synthesis--llm-wiki-self-improvement-architecture.md` — 전체 구조 기준 문서
- `wiki/lint--initial-review-2026-04-12.md` — 현재 상태와 보완점 요약
- `ops/scripts/wiki\_lint.py` — 구조 위반 탐지

- `ops/scripts/wiki\_eval.py` — binary eval baseline 산출
- `wiki/source--stage1-planning-harness-mvp.md` — planning harness bridge 의 핵심 참조

7. 결론

실행 가능한 한 줄 권고

현재 초안을 폐기하지 말고 baseline 으로 유지하되, `ops/` control layer 와 planning/meta loops 를 덧붙여 ‘지속형 위키 -> 게이트형 planning memory -> trace-first self-improvement runtime’ 순으로 진화시키는 것이 가장 실용적이다.

정리하면, 이 프로젝트의 가장 좋은 다음 단계는 ‘더 복잡한 agent system 을 추가하는 것’이 아니라 ‘현재 위키를 실제로 굴릴 수 있게 하는 contract 와 score 를 추가하는 것’이다. 그 위에서만 outer-loop 자기개선이 의미를 갖는다.

부록 A. 초기 진단과 패키지 결과

항목	초기 초안 상태	패키지 반영 후
raw path	불일치 존재	실제 파일명으로 정정
canonical pages	TODO only	27 개 wiki pages 구축
repo source retention	live web 의존	immutable snapshots 추가
lint/eval	없음	script + policy + schema 추가
self-improvement unit	정의 없음	one-mechanism keep/discard 로 명시
baseline check	없음	lint PASS, eval 149 / 149

부록 B. 참고 코드

- [D0] 업로드된 LLM Wiki 초안: AGENTS.md / wiki/index.md / wiki/log.md
- [S1] Stage 1 MVP Specification (업로드 PDF)
- [P1] Bilevel Autoresearch: Meta-Autoresearching Itself (업로드 PDF)
- [P2] SlopCodeBench: Benchmarking How Coding Agents Degrade Over Long-Horizon Iterative Tasks (업로드 PDF)
- [P3] Meta-Harness: End-to-End Optimization of Model Harnesses (업로드 PDF + project snapshot)
- [R1] karpathy/autoresearch README + program snapshot
- [R2] olelehmann100kMRR/autoresearch-skill snapshot
- [R3] byungjunjang/jangpm-meta-skills snapshot
- [R4] Q00/ouroboros README + CLAUDE snapshot